Random Forest for Regression

Random Forest एक **Ensemble Learning** method है।

👉 Ensemble का मतलब:

> कई models (यहाँ Decision Trees) को मिलाकर एक strong model बनाना।

👉 Simple भाषा में:

> Random Forest = बहुत सारे **Decision Trees** का समूह (forest 🌳🌳🌳)

हर tree अपना prediction देता है, और अंत में:

- **Classification** में → Voting (जो class ज्यादा vote पाए)
- **Regression** में → Average (सबका average)

Steps

Step 1: Bootstrap Sampling (Bagging)

- Dataset से random sampling होती है (with replacement)
- हर tree को अलग-अलग data मिलता है

👉 Example:

अगर 100 rows हैं → हर tree को 100 rows मिलेंगी, लेकिन कुछ repeat होंगी

Steps

Step 2: Random Feature Selection

- हर split पर सभी features नहीं देखे जाते
- केवल random features का subset लिया जाता है

👉 क्यों?

👉 ताकि trees अलग-अलग बनें (diversity बढ़े)

Step 3: Decision Trees बनते हैं

- हर tree independently train होता है

Step 4: Final Prediction

📌 **Classification:**

Majority Voting

📌 **Regression:**

Mean (average)

Random Forest in Both

📍 Regression vs Classification में Use

📊 Regression (continuous output)

- Example: House price prediction
- Output: number

👉 Random Forest:

➡️ सभी trees का average

🏷️ Classification (categorical output)

- Example: spam / not spam
- Output: class

👉 Random Forest:

➡️ Majority voting

Random Forest क्यों use करते हैं?

👉 क्योंकि single **Decision Tree** overfitting करता है

Random Forest:

- Variance कम करता है
- Stability बढ़ाता है
- Accuracy improve करता है

Characteristics

⚙️ Characteristics (विशेषताएँ)

- Ensemble method
- Bagging technique use करता है
- Random feature selection
- Multiple trees
- Parallel training possible

✅ Advantages

- ✔ Overfitting कम करता है
- ✔ High accuracy
- ✔ Noise handle कर सकता है
- ✔ Feature importance देता है
- ✔ Missing values को handle कर सकता है

❌ Disadvantages

- ❌ Model heavy होता है
- ❌ Slow हो सकता है
- ❌ Interpret करना मुश्किल
- ❌ Memory ज्यादा लेता है

Formula

अगर हमारे पास models हैं:

$h_1(x), h_2(x), h_3(x), \ldots, h_n(x)$

📌 **Regression:**

$$\hat{y} = \frac{1}{n} \sum_{i=1}^{n} h_i(x)$$

👉 मतलब: सभी trees का average

📌 **Classification:**

$$\hat{y} = \text{mode}(h_1(x), h_2(x), \ldots, h_n(x))$$

👉 मतलब: जो class सबसे ज्यादा बार आए

Formula

$h_1(x), h_2(x), \ldots h_n(x)$ का मतलब क्या है?

👉 यहाँ:

- **x** = आपका input data (जैसे किसी student की details, house features, etc.)
- **$h_1, h_2, h_3 \ldots h_n$** = अलग-अलग Decision Trees

👉 मतलब:

> हर tree (model) एक function है जो input x लेकर output देता है

📌 Example:

मान लो आपने 3 trees बनाए:

- $h_1(x) \rightarrow 100000$ (price predict)
- $h_2(x) \rightarrow 120000$
- $h_3(x) \rightarrow 110000$

Formula

Regression Formula का मतलब

$$\hat{y} = \frac{1}{n}\sum_{i=1}^{n} h_i(x)$$

👉 इसे आसान भाषा में:

- n = total trees
- $h_i(x)$ = हर tree का prediction
- ∑ = सबको जोड़ना

👉 Final output:

> सभी trees का **average (mean)**

Example:

3 trees हैं:

- $h_1(x) = 100$
- $h_2(x) = 120$
- $h_3(x) = 110$

$$\hat{y} = \frac{100 + 120 + 110}{3} = 110$$

👉 Final prediction = **110**

Formula in Classification

Classification Formula का मतलब

$$\hat{y} = mode(h_1(x), h_2(x), \ldots, h_n(x))$$

👉 mode = जो value सबसे ज्यादा बार आती है

Example:

3 trees prediction देते हैं:

- $h_1(x) \rightarrow$ "Spam"
- $h_2(x) \rightarrow$ "Not Spam"
- $h_3(x) \rightarrow$ "Spam"

👉 Count:

- Spam = 2
- Not Spam = 1

👉 Final output = **Spam**

✔ इसे कहते हैं **Majority Voting**

Gini Index

Gini Index क्या होता है?

👉 Gini Index बताता है:

> data कितना pure (**एक ही class का**) है

📌 **Formula:**

$$Gini = 1 - \sum p_i^2$$

👉 यहाँ:

- p_i = किसी class की probability

✔ **Gini Index**

→ data कितना pure है

→ कम Gini = अच्छा split

In Scikit-learn

Classification

Python

```python
from sklearn.ensemble import RandomForestClassifier

model = RandomForestClassifier(
    n_estimators=100,
    max_depth=5,
    random_state=42
)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Regression

Python

```python
from sklearn.ensemble import RandomForestRegressor

model = RandomForestRegressor(
    n_estimators=100,
    max_depth=5,
    random_state=42
)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Metrics for Accuracy

📏 Accuracy Check करने के Metrics

🏷️ Classification Metrics

1. Accuracy
2. Precision
3. Recall
4. F1-score
5. Confusion Matrix

👉 sklearn:

```python
from sklearn.metrics import accuracy_score, classification_report

accuracy_score(y_test, y_pred)
print(classification_report(y_test, y_pred))
```

📊 Regression Metrics

1. MAE (Mean Absolute Error)
2. MSE (Mean Squared Error)
3. RMSE
4. R^2 Score

👉 sklearn:

```python
from sklearn.metrics import mean_squared_error, r2_score

mean_squared_error(y_test, y_pred)
r2_score(y_test, y_pred)
```

Summary

Short Summary

- 👉 Random Forest = Multiple Decision Trees
- 👉 Overfitting कम करता है
- 👉 Regression → Average
- 👉 Classification → Voting
- 👉 High accuracy + robust model

What

- **M**